

A large, solid pink shape occupies the left side of the slide. Its right edge is irregular and jagged, resembling a torn piece of paper or a stylized brushstroke. The rest of the shape is a flat, solid pink rectangle.

# *Analiza defektów powierzchni metalu*

R. KUCHARSKI

A large, horizontal, pink brushstroke graphic with irregular, feathered edges, serving as a background for the title.

# *Agenda*

1. Omówienie problemu
2. Podejście nr 1
3. Podejście nr 2
4. Wnioski


# Problem

- Cel – maksymalne automatyzacja procesu(lub znaczącej części) decyzyjnego związanego z dopuszczeniem do eksploatacji uszkodzonego elementu.

Proces:



Wyniki obliczeń FEM komponentu spełniającego kryteria



2022-07-05

Analiza defektów powierzchni metalu

# Podejście 1

- Model vgg16 (Keras) + wagi modelu
- Dane treningowe i walidacyjne [gc10det](#)
- Warstwami uczonymi modelu była nowa góra „top” modelu (regresja 4 warstwy z pojedynczymi neuronami i 1 z 10 (liczba klas) do klasyfikacji)


```
inputs = keras.Input(shape=(224,224,3))
x = conv(inputs)
x1 = keras.layers.Dense(1024,activation='relu')(x)
x1 = keras.layers.Dense(512,activation='relu')(x1)

out1 = keras.layers.Dense(1,name='out1')(x1)
out2 = keras.layers.Dense(1,name='out2')(x1)
out3 = keras.layers.Dense(1,name='out3')(x1)
out4 = keras.layers.Dense(1,name='out4')(x1)

x2 = keras.layers.Dense(1024,activation='relu')(x)
x2 = keras.layers.Dropout(0.2)(x2)
x2 = keras.layers.Dense(512,activation='relu')(x2)
out_class = keras.layers.Dense(10,activation='softmax',name='out_class')(x2)

out = [out1,out2,out3,out4,out_class]

model = keras.models.Model(inputs=inputs,outputs=out)
model.summary()
```





Przykładowe dane z lokalizacjami wady – GC10DET

# Wyniki

Tak zaawansowane podejście nie sprawdziło się, pomimo znacznego wysiłku obliczeniowego – dla danych walidacyjnych z GC10DET wartość **accuracy** nie przekroczyła 30 %. Również dla danych rzeczywistych wyniki były nieakceptowalne...

[-6.9813857] [96.47233] [72.77871] [118.1076]

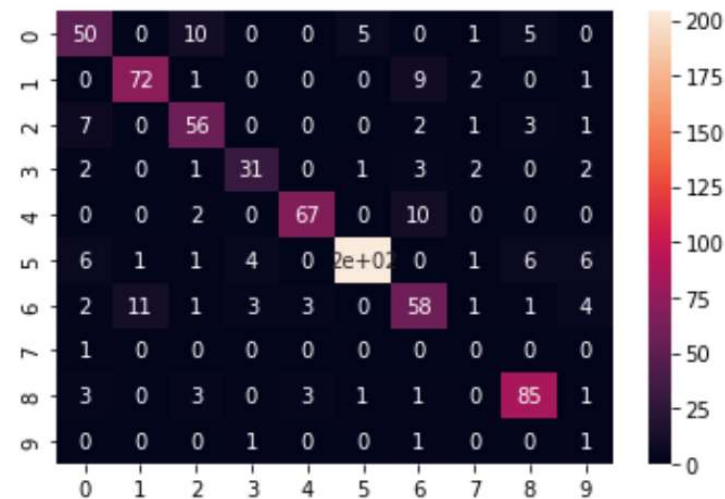
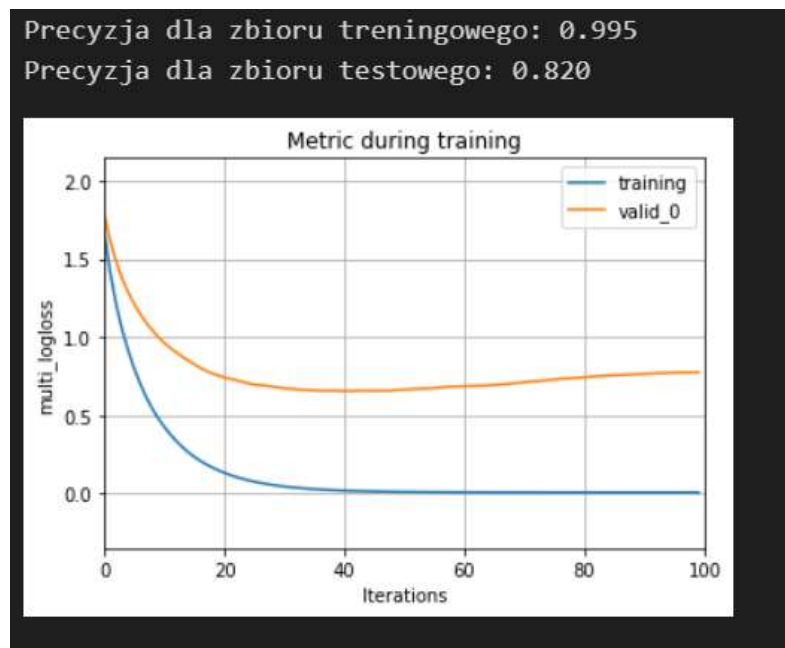


## ***Wniosek***


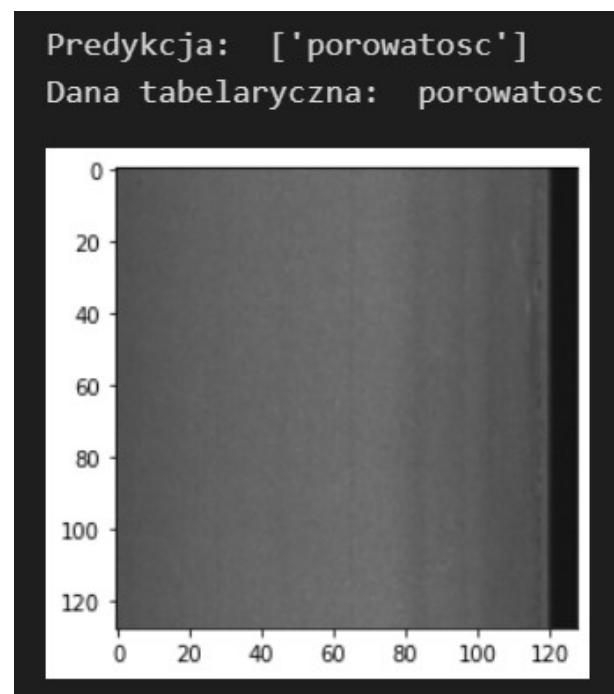
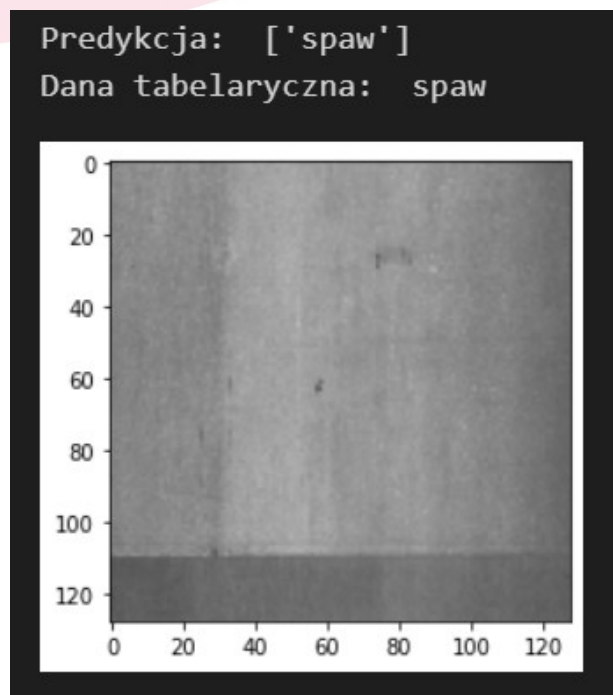
Analiza liczby zdjęć używanych w „poważnych” projektach CV doprowadziła do wniosku że danych wejściowych jest zbyt mało...

# Podejście 2\_1

- Model vgg16 (Keras) + wagi modelu użyto do inżynierii cech (na wyjściu z sieci neuronowej otrzymujemy zbiór wartości który zmieniamy na wektor kolumnowy utrzymując nasze X
- Klasyfikacja na bazie modelu LightGBM





## *Podejście 2\_2 ewaluacja na zbiorze testowym*






## *Podejście 2\_3 ewaluacja zbior rzeczywisty*




Refleksy światła powodują zafałszowanie  
klasyfikacji



Poprawna  
klasyfikacja  
porowatości

## *Podejście 2\_4 szacowanie wielkości wady*

Na bazie biblioteki scikit – image opracowano krótką funkcję która generuje własności obrazu



Różne kolory oznaczają zidentyfikowane obszary. Biblioteka pozwala wyliczyć ich względne pola i współrzędne prostokąta obwiedni. Poniżej wydruk działania – posortowanych 5 największych obszarów

	label	area	equivalent_diameter	mean_intensity	solidity	bbox-0	bbox-1	bbox-2	bbox-3
76	77	13194089	4098.687091	104.276200	0.868529	0	0	3456	4608
37	38	7716	99.117689	153.413556	0.413305	0	831	346	921
2344	2345	3100	62.825493	150.934516	0.313733	297	811	515	891
8943	8944	2188	52.781134	170.962066	0.435510	1327	0	1449	63
8808	8809	2186	52.757006	116.578683	0.280508	1185	201	1259	331

# ***Wnioski***

- Model działła lecz wyniki pozostawiają wiele do życzenia
- Możliwości poprawy – ujednolicenie sposobu wykonywania zdjęć i unikanie refleksów
- Szacowanie wielkości wad jest mocna zależne od jakości zdjęcia – wielkość zamkniętych obszarów wad może być szacowana z dokładnością do 15%

# ***Dziękuję za uwagę***

**„Tylko dlatego, że coś nie działa tak jak zamierzałeś, nie znaczy że jest bezużyteczne.”**

**Thomas Edison**